

面向分词器成员推断的站点级差分隐私与同态安全聚合方法

唐志凯¹

1. 广东外语外贸大学信息科学与技术学院（网络空间安全学院），广州 510006

E-mail: 20251010016@mail.gdufs.edu.cn

摘要：字节对编码分词器的词表与有序合并规则直接受到训练语料频率驱动，公开发布后可能泄露网站级训练成员信息。针对这一问题，本文提出安全聚合差分隐私批量字节对编码方法 SA-DP-BPE。该方法以完整网站为隐私单位，在公共候选域上对站点频率向量进行确定性 L1 截断，并利用 Paillier 加法同态加密完成多站点统计聚合；聚合服务器在密文域加入双边几何噪声，解密服务器仅获得带噪聚合并返回兼容的批量合并规则。在诚实但好奇且非共谋的双服务器模型下，Paillier 的语义安全保证训练期统计的计算机密性，站点级差分隐私则约束最终分词器发布。实验在固定版本的 C4 网站语料上评估压缩率、词表重叠、频率估计、合并相似度和朴素贝叶斯五类分词器成员推断攻击，并在 AG News 上检验下游效用。标准 Plain BPE、协议匹配无 DP 基线和主 SA-DP-BPE 的五类攻击平均原始 AUC 分别为 0.5881、0.4991 和 0.4869；逐攻击校正分数方向后，相应平均 AUC 为 0.5881、0.5283 和 0.5158。主 SA-DP-BPE 的 AG News Macro-F1 为 0.9069，与 Plain BPE 的 0.9068 基本一致。在 24 个 Paillier 参数组合的重复实测中，总耗时主要随客户端数量与候选维度的乘积增长，缩放模型拟合优度达到 $R^2 = 0.9961$ 。上述结果表明，SA-DP-BPE 在维持分词与下游效用的同时，降低了当前攻击设置下的发布侧成员风险，并实现了训练统计的密文聚合。

关键词：分词器；成员推断；站点级差分隐私；Paillier 同态加密；安全聚合

Site-Level Differential Privacy and Homomorphic Secure Aggregation against Tokenizer Membership Inference

Zhikai Tang¹

1. School of Information Science and Technology (School of Cybersecurity), Guangdong University of Foreign Studies, Guangzhou 510006, China

E-mail: 20251010016@mail.gdufs.edu.cn

Abstract: The vocabulary and ordered merge rules of a byte-pair encoding (BPE) tokenizer are driven directly by training-corpus frequencies, so a released tokenizer may reveal website-level training membership. This paper proposes Secure-Aggregated Differentially Private Batched BPE (SA-DP-BPE). Treating a complete website as the privacy unit, SA-DP-BPE applies deterministic L1 clipping to site-frequency vectors over a public candidate domain and uses Paillier additive homomorphic encryption for multi-site aggregation. The aggregation server adds two-sided geometric noise in the ciphertext domain, while the decryption server obtains only the noisy aggregate and returns a compatible batch of merge rules. Under an honest-but-curious and non-colluding two-server model, Paillier semantic security provides computational confidentiality for training statistics, and site-level differential privacy constrains the released tokenizer. Experiments on a fixed revision of C4 websites evaluate

five tokenizer membership-inference attacks—compression rate, vocabulary overlap, frequency estimation, merge similarity, and naive Bayes—together with downstream utility on AG News. The mean raw AUC values are 0.5881 for standard Plain BPE, 0.4991 for the protocol-matched non-DP baseline, and 0.4869 for the primary SA-DP-BPE configuration. After adapting the score direction separately for each attack, the corresponding mean AUC values are 0.5881, 0.5283, and 0.5158. SA-DP-BPE achieves an AG News Macro-F1 of 0.9069, compared with 0.9068 for Plain BPE. Across 24 repeatedly measured Paillier configurations, total runtime scales primarily with the product of client count and candidate dimension, and the fitted scaling model reaches $R^2 = 0.9961$. Taken together, these results show that SA-DP-BPE preserves tokenizer and downstream utility while reducing release-side membership risk under the evaluated attack setting and enabling encrypted aggregation of training statistics.

Key words: tokenizer; membership inference; site-level differential privacy; Paillier homomorphic encryption; secure aggregation

1 引言

大语言模型的数据来源往往横跨新闻、论坛、代码仓库和个人网站。模型参数是否记忆训练内容已经受到大量研究关注，但训练流程的第一个可学习组件——Tokenizer——长期被当作无敏感性的预处理。BPE Tokenizer 将高频相邻符号反复合并，最终词表与合并序列因而是训练语料频率的压缩投影。Tokenizer 体积小、推理接口简单，常与闭源模型一起公开；攻击者不必承担语言模型前向计算成本，就能比较候选网站在目标 Tokenizer 下的压缩、词表和合并特征。近期工作已从 BPE 恢复语料混合比例 [1]，并系统提出五类 Tokenizer 成员推断攻击 [2]。

同态加密与差分隐私分别对应这一问题的两个层面。同态加密隐藏上传和聚合过程中的单客户端计数，但正确解密保持最终 Tokenizer 的输出分布；差分隐私通过随机化约束发布物对单个网站的依赖。本文因此把训练期机密性与发布期成员隐私拆成两个安全目标，并分别采用 Paillier 加法同态聚合与站点级差分隐私实现。

选择“站点”而非“文档”为隐私单位来自攻击问题本身：攻击者判断的是某个完整网站是否参与 Tokenizer 训练。网站级邻接关系直接刻画完整网站的加入或删除，避免 document-level DP 经群体隐私换算时随文档数放大预算。本文在每轮对一个网站的候选词对频率向量施加 L1 上界，使单轮 add/remove 站点敏感度可控，再采用整数双边几何机制。为减少逐次 BPE 带来的隐私组合与密码学交互，协议每轮选择最多 b 个互不冲突合并。

本地差分隐私要求各站点在上传前独立加入噪声，其优势是不依赖可信聚合方，但多客户端噪声叠加可能降低高维词对统计的可用性。本文采用另一条协同防御路径：站点先在公共候选域上执行范数截断，再通过 Paillier 密文聚合隐藏原始计数，最后仅对聚合结果加入一次站点级噪声。该设计以非共谋双服务器为附加信任条件，换取更集中的噪声控制。Local-DP-BPE 作为对照，用于观察两种噪声位置对成员风险和下游效用的影响；由于两者采用不同隐私预算，该比较反映配置层面的隐私-效用差异，而非同预算严格对照。

本文的主要工作包括以下四个方面。第一，在固定版本的 C4 网站语料及互斥数据划分上，复现压缩率、词表重叠、频率估计、合并相似度和朴素贝叶斯五类分词器成员推断攻击，并报告 ROC AUC、低误报率性能和网站级 bootstrap 区间。第二，提出 SA-DP-BPE 协议，将公共候选、站点级截断、离散噪声和批量兼容合并统一到双服务器安全聚合框架中。第三，在 DCRA 和非共谋假设下分析 Paillier 聚合的计算机密性，并利用站点级敏感度与基本顺序组合给出发布机制的隐私保证。第四，通过 C4 分词效用、AG News 下游分类以及真实 2048-bit Paillier 开销实验，评估方法的隐私、效用和计算成本。

2 相关工作

2.1 成员推断与隐私审计

Shokri 等以影子模型建立黑盒成员推断范式 [3], ML-Leaks 随后放宽对目标结构和同分布影子数据的假设 [4]。Carlini 等强调似然比检验和极低误报率处的性能 [5], 难度校准研究则说明样本本身的难易度会混淆成员信号 [6]。因此, 可靠评估需要同时报告完整 ROC、低误报率性能, 并预先固定评分方向。

大模型场景进一步暴露了时间分布漂移和未知训练集问题。数据集推断研究表明, 不同分布的非成员可制造虚假的攻击成功 [7]; 自提示校准尝试从目标模型构造更贴近的参考分布 [8]。PANORAMIA 用生成非成员减少重训练依赖 [9], OSLO 强调 TPR@0.1% FPR 等低误报指标 [10], Cascading/Proxy MIA 则系统讨论自适应影子模型与成员依赖 [11]。视觉语言与扩散模型上的工作显示集合级成员推断同样适用于多种生成模型 [12–14]。

IMIA 使用黑盒分类模型的概率输出训练少量目标感知模仿模型, 以缩放置信度刻画查询样本在目标模型、模仿成员行为和模仿非成员行为之间的距离 [39]。它以模仿训练替代大量目标无关影子模型, 并通过固定方差似然比形式的距离分数完成判别。由于 IMIA 面向分类模型概率输出, 而本文攻击直接作用于分词器词表、合并规则和编码行为, 二者采用定性比较, 不纳入同一数值评估。

训练数据抽取展示了大模型可能逐字输出记忆内容 [15], 而隐私后门可由不可信预训练权重主动放大后续微调泄露 [16]。此外, 恶意训练代码提供方甚至能在保持模型效用的同时植入更强成员信号 [17]。这些主动威胁说明“发布物没有明显异常”不是安全证据。本文聚焦诚实执行的 Tokenizer 训练以及发布后的被动成员推断。恶意训练器与主动投毒属于更强的攻击模型, 需要结合认证、范围证明和鲁棒聚合机制另行分析。

差分隐私审计从另一方向给出经验下界。Jagielski 等利用投毒审计 DP-SGD 实现 [18], Nasr 等提高自然数据上的审计紧致性 [19], Steinke 等将多次独立包含/排除压缩到一次训练运行 [20]。形式化计划画机制级保证, 攻击曲线刻画特定攻击条件下的经验风险, 本文同时报告二者以形成互补分析。

2.2 Tokenizer 与 BPE 泄露

BPE 通过迭代合并高频相邻单元处理稀有词 [21], SentencePiece 展示了语言无关的工程实现 [22]。合并序列同时记录了语料统计。Hayase 等利用有序词表推断预训练数据的类别混合比例 [1]; Tong 等进一步把目标提升为“某个数据集是否参与训练”, 并提出本文复现的五种攻击 [2]。与模型损失攻击相比, Tokenizer 攻击成本低, 且发布物通常可白盒读取。

Tokenizer 泄露还具有“训练目标与攻击统计同源”的特点: BPE 为减少编码长度而偏向训练语料中的高频串, 攻击者恰好观察压缩率、词表包含关系和合并次序。删除低频 token 会同时弱化独特串和压缩能力, 因此需要联合考察隐私与效用。本文在每个防御 Tokenizer 上运行全部五种攻击, 并使用统一的留出效用语料和下游分类器进行综合评价。

2.3 差分隐私与安全聚合

差分隐私通过邻接数据集上输出分布的似然比限制个体影响 [23, 24]。DP-SGD 将裁剪与噪声用于梯度训练 [25]; RDP 和最优组合可提供更紧会计 [26, 27]。本文处理整数计数, 选择双边几何机制; 离散高斯工作说明精确离散采样对避免浮点漏洞的重要性 [28], 几何机制则具有经典的计数查询效用依据 [29]。

Paillier 基于复合剩余类提供概率加密和加法同态性 [30]。实用安全聚合可通过掩码与掉线恢复构造 [31], 也存在单服务器低通信方案 [32]。本文采用 Paillier, 主要利用其加法同态性构造可直接验证的“客户端加密—密文聚合—噪声加入—解密选择”流程。SIGuard 指出安全计算的输出仍可能遭成员推断 [33], 这支持本文将协议匹配无 DP 基线 with DP 防御分开。SOFT、Diffence 和 DOPPLER 分别从数据扰动、输入重生及优化器降噪改进隐私效用 [34–36], 与本文保护 Tokenizer 训练统计及发布物的目标互补。

现有近年防御主要作用于模型训练、微调或安全计算输出, 直接面向 Tokenizer 训练统计及发布成员风险的方案仍较少。因此, 本文的数值实验采用任务匹配的机制级基线。鉴于相关方法的保护对象和实验任务不同, 表1仅从作用阶段、隐私技术和安全假设进行定性比较。

表 1 近三年相关攻击与防御的作用层次比较
Table 1 Comparison of recent attacks and defenses by protection layer

方法	年份	保护或攻击对象	作用阶段	隐私技术	主要假设
Tokenizer MIA [2]	2026	Tokenizer: BPE 词表与合并规则	发布后攻击	无	目标分词器可查询或读取, 并具备候选网站与辅助数据
IMIA [39]	2026	分类模型概率输出 (非 Tokenizer)	发布后攻击	无	黑盒概率输出、同分布辅助数据及少量目标感知模仿模型
SIGuard [33]	2025	安全推理预测输出 (非 Tokenizer)	推理输出防御	MPC 输出扰动	半诚实安全推理参与方, 可在密文置信向量上构造扰动
SOFT [34]	2025	LLM 微调数据 (非 Tokenizer)	训练期防御	样本改写	可识别并改写高影响微调样本
Difference [35]	2025	分类器输入 (非 Tokenizer)	推理前防御	扩散重生成	扩散模型重生成输入, 并选择保持预测标签的重构
DOPPLER [36]	2024	模型训练梯度 (非 Tokenizer)	训练期防御	差分隐私	可控制 DP 优化过程并对梯度序列应用低通滤波
SA-DP-BPE	2026	Tokenizer: 站点词对计数与分词器	训练与发布	站点级 DP 与 Paillier	客户端提交合法计数; 双服务器诚实但好奇且非共谋

3 预备知识

3.1 BPE 分词器与攻击指标

设第 r 轮词表为 V_r 。字节对编码 (byte-pair encoding, BPE) 统计符号序列中的相邻词对, 选择高频词对 (u, v) 并以新符号 uv 替换。发布物包含词表和有序合并列表, 因而构成训练频率的压缩投影。本文复现的五类攻击分别观察候选网站在目标分词器下的压缩率、词表重叠、频率估计、合并顺序相似度和朴素贝叶斯特征。攻击实现预先固定“分数越大越像成员”, 真实标签只在最终度量阶段使用。

原始 ROC AUC 保留冻结分数方向。设共有 J 种攻击, AUC_j 是第 j 种攻击的实测 AUC。为避免把低于 0.5 的 AUC 自动解释为更安全, 本文对每种攻击分别适配方向后再求平均:

$$\overline{\text{AUC}}_{\text{adapt}} = \frac{1}{J} \sum_{j=1}^J \max\{\text{AUC}_j, 1 - \text{AUC}_j\}, \quad D_{\text{AUC}} = \frac{1}{J} \sum_{j=1}^J 2|\text{AUC}_j - 0.5|. \quad (1)$$

其中单项 $2|\text{AUC}_j - 0.5|$ 及其平均值 D_{AUC} 统称“AUC 偏离度” (AUC deviation), 只衡量 AUC 偏离随机猜测的程度, 不等同于密码学或统计学中严格定义的 membership advantage。式 (1) 不改变原攻击器, 也不等同于已经执行防御感知的自适应攻击; 尤其不能先求原始 AUC 均值再整体翻转。

3.2 站点级差分隐私

定义 1 (站点级 add/remove 邻接) 设数据集 $\mathcal{D} = (D_1, \dots, D_N)$ 的每个 D_i 包含一个完整网站的全部文本。若 $\mathcal{D}$ 与 $\mathcal{D}'$ 恰好相差一个完整网站的加入或删除, 则称二者站点级相邻, 记为 $\mathcal{D} \simeq \mathcal{D}'$ 。全文只采用该 add/remove 定义, 不与 replace-one 邻接混用。

定义 2 (站点级纯差分隐私) 随机机制 $\mathcal{M}$ 若对任意 $\mathcal{D} \simeq \mathcal{D}'$ 和任意可测输出集合 S 满足

$$\Pr[\mathcal{M}(\mathcal{D}) \in S] \leq e^\epsilon \Pr[\mathcal{M}(\mathcal{D}') \in S], \quad (2)$$

则称其满足站点级 ϵ -差分隐私 (differential privacy, DP)。

对 L1 敏感度为 Δ_1 的整数向量查询, 实现中通过两个独立几何随机变量之差采样双边几何噪声, 其概率质量函数为

$$\Pr[Z = z] = \frac{1 - \alpha}{1 + \alpha} \alpha^{|z|}, \quad \alpha = \exp(-\epsilon/\Delta_1), \quad z \in \mathbb{Z}. \quad (3)$$

噪声值采用任意精度整数表示, 以避免定宽整数转换造成溢出。

3.3 Paillier 加法同态密码体制

Paillier 是概率型加法同态公钥密码体制，而非完全同态加密 [30]。密钥生成取等长大素数 p, q ，令

$$n = pq, \quad \lambda = \text{lcm}(p-1, q-1), \quad L(u) = \frac{u-1}{n}. \quad (4)$$

选择 $g \in \mathbb{Z}_{n^2}^*$ 使 $\gcd(L(g^\lambda \bmod n^2), n) = 1$ ，并计算

$$\mu = [L(g^\lambda \bmod n^2)]^{-1} \bmod n. \quad (5)$$

于是公钥和私钥分别为

$$pk = (n, g), \quad sk = (\lambda, \mu). \quad (6)$$

明文空间为 $\mathbb{Z}_n$ ，密文属于 $\mathbb{Z}_{n^2}^*$ 。对消息 $m \in \mathbb{Z}_n$ ，随机选取 $r \leftarrow \mathbb{Z}_n^*$ ，加密与解密分别为

$$c = E_{pk}(m; r) = g^m r^n \bmod n^2, \quad (7)$$

$$m = D_{sk}(c) = L(c^\lambda \bmod n^2) \mu \bmod n. \quad (8)$$

随机数 r 使同一明文的两次诚实加密以高概率产生不同密文。对任意合法消息和标量 a ，有

$$E(m_1; r_1)E(m_2; r_2) = E(m_1 + m_2; r_1 r_2) \pmod{n^2}, \quad (9)$$

$$E(m; r)^a = E(am; r^a) \pmod{n^2}. \quad (10)$$

式 (9) 中的明文加法在模 n 上进行。

协议需要表示负噪声。抽象分析采用中心提升编码：整数 a 编为 $[a]_n$ ；解码时将小于 $n/2$ 的剩余类解释为非负整数，其余解释为 $a - n$ 。实验原型采用 **phe** 的有符号定点编码，并以 **precision=1** 表示整数；该库使用比 $n/2$ 更保守的安全区间检测溢出。若每个坐标的真实和 s 满足 $|s| < B_n$ (B_n 为有符号解码安全界)，解密后得到整数 s ；否则只得到模 n 的剩余类并可能回绕。

正式密码学开销实验请求 2048-bit 密钥，即调用密钥生成时令模数目标长度为 2048 bit，并在结果中检查实际 $n.\text{bit_length}() \geq 2048$ 。这里的“2048-bit”指公开模数 n 的位数，不表示 2048 bit 对称安全，也不意味着使用门限解密。主分词器矩阵为控制总成本采用协议等价明文聚合；真实 Paillier-2048 的正确性和分阶段成本在独立正式矩阵中测量。

表 2 主要符号
Table 2 Key notation

符号	含义
P_i	第 i 个站点客户端
A	无私钥的聚合服务器
D	持私钥的解密与选择服务器
C_r	第 r 轮站点级 L1 截断上界
K	公开候选词对维度
b	每轮最大兼容合并数
R	批量 BPE 实际轮数
ε_r	第 r 轮隐私预算

4 系统模型与威胁模型

4.1 参与方与安全目标

系统包含站点客户端 P_i 、聚合服务器 A 、解密服务器 D 和发布后攻击者 M 。每个 P_i 持有一个网站的私有文本 D_i 。 A 维护公开候选域、接收单客户端密文并执行同态聚合，但不持有私钥。 D 持有私钥，

只接收带噪聚合密文，解密后执行兼容 top- b 选择并返回合并标识。 M 获得最终 Tokenizer、候选网站文本和可能的公开辅助资料，可黑盒查询编码，也可白盒读取词表及合并序列。

本文采用诚实但好奇且非共谋的双服务器模型。客户端按照协议生成合法计数向量与密文，聚合服务器和解密服务器均遵循协议流程，但可能分析各自可见的信息。安全目标包括训练期单站点统计的计算机密性以及最终分词器发布的站点级成员隐私。

训练期机密性要求 A 无法由单客户端上传恢复站点计数，且 D 只接收带噪聚合而不接触单客户端密文；该目标由 Paillier 语义安全和角色分离支持。发布期站点成员隐私要求最终 Tokenizer 对加入或删除一个完整网站的分布变化受到隐私预算约束；该目标由站点截断、离散噪声和隐私会计共同实现。协议匹配无 DP 基线保留公共候选与批量训练路径，用于刻画训练机制本身对成员风险的影响。

4.2 协议视图

定义 3 (协议视图) 固定安全参数 κ 、第 r 轮公共状态和各参与方随机性，定义

$$\begin{aligned} \text{View}_A &= (pk, Q_r, \{E_{pk}(\bar{x}_{i,r})\}_{i=1}^N, z_r, E_{pk}(z_r), C_r^{\text{agg}}, C_r^{\text{noisy}}, \text{meta}_r), \\ \text{View}_D &= (pk, sk, C_r^{\text{noisy}}, y_r, \text{IDs}_r, \text{meta}_r), \\ \text{View}_M &= (T_{\text{final}}, D^*, \text{aux}, \text{query transcripts}), \end{aligned}$$

其中 Q_r 为公开候选， $\bar{x}_{i,r}$ 为截断站点向量， z_r 为 A 采样的噪声， $y_r = \sum_i \bar{x}_{i,r} + z_r$ ， IDs_r 为返回的合并标识， T_{final} 为最终 Tokenizer。协议元数据包含维度、轮次、候选哈希和消息长度，但不包含私有明文。

该定义明确 A 掌握自身采样的噪声明文及其密文， D 掌握带噪聚合明文；在非共谋执行中，二者的视图均不足以同时获得单站点上传、独立噪声与解密能力。若 A 与 D 共谋，则可结合 z_r 、 y_r 和私钥恢复未扰动聚合或单客户端计数，训练期内部机密性随之失效。只要随机化与发布步骤仍按协议执行，外部 Tokenizer 的抽象站点级差分隐私分布仍由随机机制决定。该区分将内部计算机密性、外部发布隐私与非共谋信任假设分别刻画。




图 1 SA-DP-BPE 十步协议流：HE 保护中间统计量，DP 约束最终发布

Figure 1 Ten-step SA-DP-BPE flow: HE protects intermediate statistics, whereas DP constrains the final release

表 3 参与方可见信息与边界
Table 3 Visible information and trust boundaries

实体	可见信息	不可见或不保证
P_i	自身站点、 pk 、公开候选与 Tokenizer 状态	其他站点明文、 sk
A	单客户端密文、公开候选、自身采样的噪声明文及密文、聚合密文、协议元数据	sk 、单站点明文、带噪聚合明文
D	pk, sk 、带噪聚合密文及明文、top- b 标识	单客户端密文、独立噪声值
M	最终 Tokenizer、候选网站、辅助语料与查询结果	训练期私有统计

来源：本文协议定义与诚实但好奇、非共谋的双服务器威胁模型。

5 SA-DP-BPE 协议

5.1 公开候选与站点级截断

私有语料若直接用于明文发现候选词对，候选集本身便会泄露频率信息。本文为每个数据划分设置与成员网站、非成员网站和影子辅助网站严格互斥的公共候选网站。第 r 轮， A 按当前公开 Tokenizer 对公共语料重新分词，从公共频率最高且尚未合并的词对中确定性选取至多 K 个候选

$$Q_r = (q_{r,1}, \dots, q_{r,K_r}), \quad K_r \leq K, \quad (11)$$

并发布候选哈希。客户端 P_i 只计算

$$x_{i,r}[j] = \text{count}_{D_i}(q_{r,j}) \in \mathbb{N}. \quad (12)$$

截断界 C_r 由公共候选网站在本轮的 L1 范数分布取预先选定的分位数并向上取整，计算过程与私有站点范数相互独立。对非负向量 $\mathbf{x}$ ，理想缩放为

$$\mathbf{y} = \mathbf{x} \min \left\{ 1, \frac{C_r}{\|\mathbf{x}\|_1} \right\}. \quad (13)$$

为适配整数噪声和 Paillier 明文，本文以确定性最大余数法整数化式 (13)：先逐坐标下取整，再按小数余量降序、坐标索引升序补足剩余单位。所得 $\bar{x}_{i,r} \in \mathbb{N}^{K_r}$ 满足

$$\|\bar{x}_{i,r}\|_1 \leq C_r, \quad (14)$$

且同一输入产生相同输出。任意精度整数路径避免先转为定宽 NumPy 整数造成静默溢出。

5.2 密文聚合与离散噪声

D 运行 $\text{KeyGen}(1^\kappa)$ 并把 pk 分发给客户端和 A 。客户端逐坐标随机加密截断向量。 A 不持有 sk ，计算

$$C_{r,j}^{\text{agg}} = \prod_{i=1}^N E_{pk}(\bar{x}_{i,r}[j]) = E_{pk} \left(\sum_{i=1}^N \bar{x}_{i,r}[j] \right). \quad (15)$$

A 以敏感度 C_r 和单轮预算 ε_r 独立采样式 (3) 的 $z_{r,j}$ ，然后计算

$$C_{r,j}^{\text{noisy}} = C_{r,j}^{\text{agg}} E_{pk}(z_{r,j}). \quad (16)$$

D 仅解密整条带噪聚合向量，按值降序、索引升序排序候选并选择最多 b 个兼容合并；它不向 A 返回频率，只返回 merge IDs。

兼容性规则避免同一批次产生依赖环：设已选规则的左、右符号集合分别为 L_r, R_r ，新候选 (u, v) 仅当 $u \notin R_r, v \notin L_r$ 且输出符号 uv 未被本批使用时接纳。top- b 的排序复杂度按实际全排序实现为 $O(K \log K)$ 。该批处理路径减少交互轮数，但与标准逐轮 Plain BPE 的训练轨迹并不相同。

算法 1 SA-DP-BPE 单轮训练协议

Input: 公共候选语料, 客户端网站 D_i , 公开状态, K, b, C_r, ε_r
Output: 至多 b 个兼容 merge IDs 与更新后的公开状态

- 1 A 由公共语料发布 Q_r 与候选哈希;
- 2 **foreach** 客户端 P_i **do**
- 3 统计 $\mathbf{x}_{i,r}$, 截断整数化为 $\bar{\mathbf{x}}_{i,r}$;
- 4 向 A 上传 $E_{pk}(\bar{\mathbf{x}}_{i,r})$;
- 5 **end**
- 6 A 按式 (15) 同态聚合;
- 7 A 采样 $\mathbf{z}_r$, 按式 (16) 加入加密噪声;
- 8 A 向 D 发送 C_r^{noisy} ; D 解密并执行兼容 top- b ;
- 9 D 仅返回 merge IDs; 协调端更新并发布本轮 Tokenizer 状态;

5.3 轮数与隐私会计

若目标词表比初始词表需新增 M 个 merge, 则计划轮数为

$$R_{\text{plan}} = \lceil M/b \rceil, \quad \varepsilon_r = \varepsilon_{\text{total}}/R_{\text{plan}}. \quad (17)$$

隐私会计采用基本顺序组合, 并按轮统计 C_r 、 ε_r 、候选数、选中合并、实际词表和噪声 L1 范数。主评估阶段的三个私有方法均按式 (17) 完成训练, 具体轮数、逐轮预算和截断范围见表 4。

表 4 主评估配置的站点级隐私会计
Table 4 Site-level privacy accounting for the main evaluation

方法与种子	ε	R	ε_r	C_r 范围	merges	提前停止
Local-DP ($\varepsilon = 16$), 20260726	16	479	0.033403	[190,61487]	15310	否
Local-DP ($\varepsilon = 16$), 20260727	16	488	0.032787	[211,65507]	15588	否
Local-DP ($\varepsilon = 16$), 20260728	16	489	0.032720	[184,66346]	15619	否
SA-DP-BPE ($\varepsilon = 8$), 20260726	8	479	0.016701	[202,61487]	15310	否
SA-DP-BPE ($\varepsilon = 8$), 20260727	8	488	0.016393	[203,65507]	15588	否
SA-DP-BPE ($\varepsilon = 8$), 20260728	8	489	0.016360	[186,66346]	15619	否
SA-DP-BPE ($\varepsilon = 4$), 20260726	4	479	0.008351	[117,39736]	15310	否
SA-DP-BPE ($\varepsilon = 4$), 20260727	4	488	0.008197	[104,37566]	15588	否
SA-DP-BPE ($\varepsilon = 4$), 20260728	4	489	0.008180	[117,37887]	15619	否

来源: 主评估阶段的逐轮隐私会计; $K = 1024$ 、 $b = 32$, 采用基本顺序组合, 并按计划轮数均匀分配总预算。 C_r 为公共范数分布分位数形成的逐轮实际范围。

5.4 实验实现与分层验证策略

为分别评估算法层面的成员风险与效用, 以及密码学实现的正确性与运行开销, 本文采用分层验证策略。成员推断、分词效用和下游分类实验使用协议等价的明文聚合实现, 保持公共候选、站点截断、噪声采样和批量选择逻辑与密文协议一致。Paillier 密文聚合的正确性、通信量及加密、聚合和解密开销则通过独立的真实 2048-bit 实现测量。该设计能够避免密码学运算成本对大规模风险与效用评估造成干扰, 同时分别呈现算法效果和密码学部署成本。

6 正确性、隐私与机密性分析

6.1 敏感度与聚合正确性

引理 1 (单轮站点级敏感度) 固定公开候选 Q_r 。若每个站点经截断后满足 $\|\bar{\mathbf{x}}_{i,r}\|_1 \leq C_r$, 则聚合查询 $f_r(\mathcal{D}) = \sum_i \bar{\mathbf{x}}_{i,r}$ 在站点级 add/remove 邻接下的 L1 敏感度满足 $\Delta_1(f_r) \leq C_r$ 。

证明: 相邻数据集的聚合只相差被加入或删除站点的 $\bar{\mathbf{x}}_{i,r}$ 。该向量非负且 L1 范数不超过 C_r , 故 $\|f_r(\mathcal{D}) - f_r(\mathcal{D}')\|_1 \leq C_r$ 。 $\square$

命题 1 (Paillier 聚合正确性) 设第 j 个坐标的整数和

$$s_{r,j} = \sum_{i=1}^N \bar{x}_{i,r}[j] + z_{r,j} \quad (18)$$

落在 Paillier 实现的有符号解码安全区间内, 则 D 对式 (16) 解密并有符号解码后逐坐标恰得 $s_{r,j}$ 。

证明: 反复应用式 (9), 有

$$\begin{aligned} C_{r,j}^{\text{noisy}} &= \left(\prod_i E_{pk}(\bar{x}_{i,r}[j]) \right) E_{pk}(z_{r,j}) \\ &= E_{pk} \left(\sum_i \bar{x}_{i,r}[j] + z_{r,j} \right) \pmod{n^2}. \end{aligned}$$

由式 (8) 得到 $[s_{r,j}]_n$; 安全区间条件保证中心提升 (实际为 **phe** 的保守有符号解码) 唯一恢复整数 $s_{r,j}$ 。□

6.2 聚合服务器机密性

定理 1 (聚合服务器视图的计算机机密性) 若判定复合剩余假设 (decisional composite residuosity assumption, DCRA) 成立、客户端诚实加密且 A 与 D 不共谋, 则对任意两个同维度、同公开元数据的诚实客户端截断向量集合, A 的视图中由客户端明文决定的部分计算不可区分。特别地, A 不能以非可忽略优势由 View_A 恢复任一诚实客户端的计数向量。

证明: Paillier 在 DCRA 下满足选择明文攻击下的不可区分性 (IND-CPA)。把客户端编号为 $t \in \{1, \dots, N\}$, 把每个向量的坐标编号为 $j \in \{1, \dots, K\}$ 。定义内层混合 $H_{t,j}$ (其中 $j \in \{0, \dots, K\}$): 前 $t-1$ 个客户端的全部坐标已经替换为零消息的独立随机加密; 第 t 个客户端的前 j 个坐标已经替换为零消息加密, 其余坐标仍是真实消息加密; 后续客户端也保持真实密文。于是 $H_{1,0}$ 是全真实密文视图, $H_{t,K}$ 与 $H_{t+1,0}$ 是同一分布, 而 $H_{N,K}$ 是全零消息密文视图。 A 持有 pk , 故它对客户端密文执行的乘法、对自身噪声的随机加密以及聚合密文的构造均为公开的多项式时间变换。

固定任意 t 和 $j \geq 1$, 相邻混合 $H_{t,j-1}$ 与 $H_{t,j}$ 只在第 t 个客户端的第 j 个密文上不同。若存在多项式时间区分器以非可忽略优势区分二者, 则构造 Paillier IND-CPA 攻击者: 它把该坐标的真实消息与零消息提交给挑战者, 将返回的挑战密文填入位置 (t, j) , 并利用公开密钥自行随机加密所有其余真实或零坐标, 随后诚实生成噪声明文、噪声密文、聚合密文及公开协议元数据。区分器的输出即可用于猜测挑战比特, 与 IND-CPA 矛盾。因此对每个坐标都有

$$H_{t,j-1} \approx_c H_{t,j}. \quad (19)$$

沿客户端和坐标的字典序进行 NK 次标准混合, 并使用 $H_{t,K} \equiv H_{t+1,0}$, 得到 $H_{1,0} \approx_c H_{N,K}$ 。故在服务器不共谋时, A 无法从客户端密文视图中计算恢复诚实客户端的站点计数向量。

该结论是计算机机密性而非信息论安全。它也不隐藏向量维度、轮数、候选域或消息长度, 并且不认证客户端输入。□

6.3 站点级差分隐私与组合

定理 2 (抽象整数机制的单轮站点级 DP) 固定此前公开输出和公共候选规则。若第 r 轮对 $f_r(\mathcal{D})$ 的每个坐标加入式 (3) 的独立噪声, 且 $\alpha_r = \exp(-\varepsilon_r/C_r)$, 则定义在整数域上的带噪聚合机制满足站点级 ε_r -DP。

证明: 对任意相邻 $\mathcal{D} \simeq \mathcal{D}'$ 和任意输出向量 $\mathbf{o} \in \mathbb{Z}^{K_r}$, 概率质量之比为

$$\frac{\Pr[f_r(\mathcal{D}) + \mathbf{Z}_r = \mathbf{o}]}{\Pr[f_r(\mathcal{D}') + \mathbf{Z}_r = \mathbf{o}]} = \alpha_r^{\|\mathbf{o} - f_r(\mathcal{D})\|_1 - \|\mathbf{o} - f_r(\mathcal{D}')\|_1}$$

$$\begin{aligned} &\leq \alpha_r^{-\|f_r(\mathcal{D}) - f_r(\mathcal{D}')\|_1} \\ &\leq e^{\varepsilon_r}, \end{aligned}$$

其中最后一步使用单轮敏感度引理。对输出集合求和即得式 (2)。 $\square$

定理 3 (多轮基本顺序组合) 若第 r 轮在给定此前所有发布结果后满足站点级 ε_r -DP, 则 R 轮自适应训练轨迹满足

$$\varepsilon_{\text{total}} = \sum_{r=1}^R \varepsilon_r \quad (20)$$

的站点级 DP。本文采用基本顺序组合进行纯差分隐私会计, 即 $\delta = 0$ 。

证明: 把完整轨迹的联合概率分解为逐轮条件概率之积。每个条件概率比至多为 e^{ε_r} , 相乘得到 $e^{\sum_r \varepsilon_r}$ 。候选可依赖先前公开输出, 但固定条件历史后仍只使用公共候选语料和本轮机制, 故自适应组合成立。 $\square$

推论 1 (后处理) 兼容 top- b 选择、merge IDs 发布、BPE 状态更新和最终 Tokenizer 构造均为带噪聚合轨迹的后处理, 不增加式 (20) 的隐私预算。

6.4 有限模空间、无界噪声与共谋

定理 2 描述定义在整数域上的双边几何机制。Paillier 明文空间为有限环 $\mathbb{Z}_n$, 因此正确解码要求带噪聚合落在有符号编码的安全区间内。本文采用 2048-bit 模数, 在全部实测配置中均通过编码与解码一致性检验。若需要在有限模域上建立不依赖安全区间条件的严格隐私保证, 可采用周期化离散机制, 或将尾部概率纳入 (ε, δ) -差分隐私分析。

服务器职责分离是训练期机密性的关键条件。 A 掌握 $\mathbf{z}_r$ 及单客户端密文, D 持有私钥并掌握 $\sum_i \mathbf{x}_{i,r} + \mathbf{z}_r$ 。两服务器共谋时可结合这些视图恢复单客户端计数或未扰动聚合, 因而内部计算机密性依赖非共谋假设。若随机化与发布步骤仍按协议执行, 外部 Tokenizer 的抽象站点级差分隐私分布继续由随机机制约束。面向共谋场景, 门限 Paillier 与多方噪声生成可增强内部保护。

表 5 安全性质、理论依据与适用条件
Table 5 Security properties, foundations, and conditions

安全性质	理论依据	适用条件或扩展方向
单客户端上传机密性	DCRA 下 Paillier IND-CPA 混合论证	诚实加密与服务器非共谋
发布后站点成员隐私	截断、整数几何机制与基本组合	有限模域可结合周期机制或 δ 分析
聚合正确性	同态等式与有符号安全区间	带噪聚合位于安全解码区间
服务器职责分离	非共谋双服务器模型	共谋场景可采用门限解密和多方噪声
主动安全扩展	范围证明与认证机制	可结合鲁棒聚合及侧信道防护

来源: 本文协议定义与形式化分析; HE 与 DP 分别对应训练期机密性和发布期隐私。

7 实验设置

7.1 数据集划分与参数选择

网站语料来自固定版本 1588ec454efa 的 allenai/c4 [37], 包含 960 个自然网站、33524 篇文本和 74238126 字节。数据集划分包括成员网站、非成员网站、影子辅助网站和公共候选网站, 各部分保持严格互斥。开发集用于参数搜索和配置选择, 独立主评估集仅在配置确定后用于最终攻击、效用和下游性能评估, 从而避免主评估信息参与参数选择。三个随机种子为 20260726、20260727 和 20260728, 具体规模见表 6。

参数选择阶段采用预先设定的单因素设计, 覆盖 $\varepsilon \in \{0.5, 1, 2, 4, 8, 16\}$ 、截断分位数 $\{50, 75, 90\}$ 、 $b \in \{1, 8, 32, 64\}$ 和 $K \in \{512, 1024, 2048, 4096\}$ 。候选配置依据五类攻击平均 AUC、留出 C4 语料的 token 增长和 AG News 验证集 Macro-F1 综合筛选, 并在独立主评估开始前确定最终方法配置。

表 6 C4 网站数据划分
Table 6 C4 website partitions

规模	种子	目标	成员	非成员	影子辅助	公开候选
开发集	20260726	128	64	64	32	32
开发集	20260727	128	64	64	32	32
开发集	20260728	128	64	64	32	32
主评估集	20260726	512	256	256	128	128
主评估集	20260727	512	256	256	128	128
主评估集	20260728	512	256	256	128	128

目标网站由等量成员与非成员组成；影子辅助网站和公共候选网站均与目标网站互斥。

7.2 攻击、基线与统计口径

Plain BPE 的词表规模覆盖 4k、8k、16k 和 32k，确定性基线为 Min-count BPE（阈值 2、5 和 10）。五类攻击中，词表重叠与合并相似度使用 32 个影子分词器，频率估计使用 1 个影子分词器及 10 组辅助抽样，朴素贝叶斯使用 10 组辅助成员集合，压缩率攻击直接由目标分词器计算。防御评估复用预先训练的 Plain BPE 影子分词器，因此对应结果属于迁移攻击。

评价指标包括 ROC AUC、Average Precision、Balanced Accuracy、 $\text{TPR@FPR} \leq 1\%$ 和 $\text{TPR@FPR} \leq 0.1\%$ 。每种攻击采用 10,000 次分层网站级 bootstrap 估计区间，方法差异使用相同网站索引的配对分层 bootstrap。三个随机种子报告均值与样本标准差。原始攻击分数方向保持固定，并按式 (1) 补充逐攻击方向适配指标。




图 2 成员推断攻击评估流程

Figure 2 Membership-inference evaluation workflow

成员标签仅用于最终指标计算，不参与攻击评分函数的确定。

7.3 Tokenizer 效用与下游任务

Tokenizer 效用在同一组留出 C4 非成员网站上计算 bytes/token、tokens/document、实际词表规模、merge 数和训练时间。bytes/token 越大，表示编码相同字节所需 token 越少。下游任务采用 AG News 四分类 [38]：从官方训练集分层划分 90%/10% 的训练集和验证集，在验证集选择最优模型后对测试集评估一次。所有 Tokenizer 共用两层 Transformer Encoder，参数为 embedding 128、4 个注意力头、FFN 256、最大长度 256、dropout 0.1、AdamW 学习率 10^{-3} 、有效 batch 64、最多 8 epoch 和 patience 2。

标准 Plain BPE、协议匹配无 DP 基线、Local-DP-BPE 和两种 SA-DP-BPE 承担不同的对照作用。协议匹配无 DP 基线与 SA-DP-BPE 共享公共候选、批量训练和聚合接口，但不加入差分隐私噪声。成员风险、分词效用和下游分类采用协议等价明文聚合，以考察候选、截断、随机化和批量选择对算法结果的影响；真实 Paillier 则用于独立的正确性与开销测量。Local-DP-BPE 的隐私预算为 $\epsilon = 16$ ，主

SA-DP-BPE 为 $\varepsilon = 8$, 另一 SA-DP-BPE 为 $\varepsilon = 4$, 共同呈现不同配置下的隐私-效用权衡。

7.4 真实 Paillier-2048 开销实验

密码学开销实验考察客户端数量 N 与候选维度 K 对协议成本的影响。客户端数量取 $N \in \{2, 4, 8, 16, 32, 64\}$, 候选维度取 $K \in \{128, 512, 1024, 2048, 4096\}$ 。本文在其中 24 个参数组合上完成真实 2048-bit Paillier 重复测量, 每个组合包含 5 次预热和 20 次正式运行, 并基于实测结果拟合缩放模型, 对 6 个更大规模配置给出预测区间。实测值和模型预测值在表格及图中分别标记, 以分析密码学开销随客户端数量和候选维度的变化规律。KeyGen 属于每个密钥对的一次性离线操作, 本节的开销分析聚焦在线加密、聚合、噪声加入与解密阶段。

表 7 协议参与方的计算与通信复杂度

Table 7 Computation and communication costs by protocol party

阶段	执行方	计算复杂度	通信复杂度
本地截断与编码	客户端	$O(K)$	无
Paillier 加密	客户端	$O(K)$ 次加密	K 个密文
密文聚合	聚合服务器 A	$O(NK)$ 次模乘	无额外客户端通信
噪声采样与加密	聚合服务器 A	$O(K)$ 次采样和加密	无
聚合密文发送	$A \rightarrow D$	无	K 个密文
解密	解密服务器 D	$O(K)$ 次解密	无
top- b 选择	解密服务器 D	排序实现为 $O(K \log K)$	b 个 merge IDs

来源: 协议的循环与排序路径; N 为客户端数, K 为候选维度。KeyGen 是每个密钥对的一次性离线操作, 表中聚焦在线阶段。

每个 2048-bit Paillier 密文按固定长度计为 512 bytes, 客户端总上行为 $512NK$ bytes, $A \rightarrow D$ 发送 K 个密文, D 返回至多 b 个 merge IDs。开销评估同时记录逐阶段耗时、通信字节、模数实际位数以及逐坐标明文与解密结果的一致性。

8 实验结果

8.1 Plain BPE 的五类成员推断

表 8 汇总独立主评估集上 16k Plain BPE 的三种子攻击结果。频率估计攻击的平均 AUC 最高, 为 0.6990; 压缩率、词表重叠、合并相似度和朴素贝叶斯分别利用分词压缩、词表元素、合并结构和集合统计中的成员信号。

表 8 Plain BPE 五类攻击结果 (均值 $\pm$ 样本标准差)

Table 8 Five attacks on Plain BPE (mean $\pm$ sample standard deviation)

攻击	ROC AUC	AP	平衡准确率	TPR@1%	TPR@0.1%
压缩率	0.5520 $\pm$ 0.0195	0.5584	0.5560	0.0117	0.0026
频率估计	0.6990 $\pm$ 0.0391	0.7428	0.6667	0.2057	0.1250
合并相似度	0.5288 $\pm$ 0.0194	0.5268	0.5423	0.0091	0.0039
朴素贝叶斯	0.5755 $\pm$ 0.0208	0.6361	0.5879	0.1706	0.1693
词表重叠	0.5854 $\pm$ 0.0335	0.6089	0.5729	0.0677	0.0339

来源: 独立主评估集的三个随机种子; 每种攻击均采用 10,000 次分层网站级 bootstrap。

8.2 标准基线、协议匹配基线与差分隐私

表 9 比较标准 Plain BPE、协议匹配无 DP 基线、Local-DP-BPE 和两种 SA-DP-BPE。Plain BPE 与协议匹配无 DP 基线的五攻击平均原始 AUC 分别为 0.5881 和 0.4991。协议匹配基线在公共候选域、批量合并和聚合接口上与 SA-DP-BPE 保持一致, 从而刻画候选域与训练路径对成员风险的影响。

主 SA-DP-BPE 采用 $\varepsilon = 8$ 、截断阈值取公共范数分布第 75 百分位、 $b = 32$ 和 $K = 1024$, 平均原始 AUC 为 0.4869。Plain BPE 与 SA-DP-BPE 的差异体现了公共候选、批量合并和随机化的综合作用;




图 3 Plain BPE 的攻击 ROC 与词表规模敏感性

Figure 3 Attack ROC curves and vocabulary-size sensitivity for Plain BPE

差分隐私的增量影响主要通过协议匹配基线进行刻画。为避免分数方向反转造成误读，本文同时报告逐攻击方向适配 AUC: Plain BPE、协议匹配无 DP 基线和主 SA-DP-BPE 分别为 0.5881、0.5283 和 0.5158，对应 AUC 偏离度为 0.1763、0.0566 和 0.0316。协议匹配基线到主 SA-DP-BPE 的方向适配 AUC 降低约 0.0125，反映站点截断与随机化在协议匹配条件下带来的经验风险变化。上述结果对应本文设定的迁移攻击。

Local-DP-BPE 采用 $\varepsilon = 16$ ，平均原始 AUC 和方向适配 AUC 分别为 0.4876 和 0.5160；主 SA-DP-BPE 采用 $\varepsilon = 8$ 。两类方法的比较主要用于呈现不同配置下的隐私-效用权衡。

表 9 主要方法的原始与方向适配攻击指标

Table 9 Raw and direction-adapted attack metrics for the main methods

方法	平均原始 AUC	平均 AUC_{adapt}	D_{AUC}	Macro-F1
Plain BPE	0.5881	0.5881	0.1763	0.9068
协议匹配无 DP 基线	0.4991	0.5283	0.0566	0.9063
Local-DP-BPE ($\varepsilon = 16$)	0.4876	0.5160	0.0320	0.9047
SA-DP-BPE ($\varepsilon = 8$)	0.4869	0.5158	0.0316	0.9069
SA-DP-BPE ($\varepsilon = 4$)	0.4865	0.5162	0.0323	0.9045

原始 AUC 与 Macro-F1 为三个随机种子的实测汇总；平均 AUC_{adapt} 和 D_{AUC} 由五种攻击逐项派生。 D_{AUC} 表示 AUC 偏离随机猜测的程度。




图 4 五类迁移攻击的原始与逐攻击方向适配 ROC AUC

Figure 4 Raw and per-attack direction-adapted ROC AUC for five transfer attacks

右图对每种攻击分别计算 $\max(AUC_j, 1 - AUC_j)$ ，以消除评分方向的影响。

8.3 Tokenizer 效用与 AG News

在留出 C4 语料上, Plain BPE 的 bytes/token 为 4.2859, 主 SA-DP-BPE 为 4.2477, 相对变化 -0.89%, 对应约 0.89% 的压缩效率变化。协议匹配无 DP 基线为 4.3264, 表明公共候选与批量训练路径本身也会影响分词压缩特性。

AG News 上, Plain BPE 的 Accuracy/Macro-F1 为 0.9068/0.9068, 主 SA-DP-BPE 为 0.9070/0.9069, Macro-F1 差为 +0.0001。三个随机种子的平均 Macro-F1 保持在相近水平, 表明 SA-DP-BPE 在本实验设置下维持了稳定的下游分类性能。Local-DP-BPE 和 $\varepsilon = 4$ 的 SA-DP-BPE 的 Macro-F1 分别为 0.9047 和 0.9045。




图 5 Tokenizer 压缩效用与 AG News Macro-F1

Figure 5 Tokenizer compression utility and AG News Macro-F1

柱高为独立主评估集三个随机种子的实测均值。

8.4 2048-bit Paillier 实测与模型预测

密码学开销实验在 24 个参数组合上完成真实 2048-bit Paillier 重复测量, 并基于这些实测结果对 6 个更大规模配置给出预测区间。表 10 将两类来源分别标记为“实测”和“模型预测”。

表 10 2048-bit Paillier 代表配置: 实测与模型预测

Table 10 Representative 2048-bit Paillier configurations: measured and model-predicted

来源	客户端数	K	平均耗时/s	95% 区间/s	上行/MiB
实测	2	1024	15.991	[15.861, 16.117]	1.00
实测	16	1024	50.355	[49.824, 51.017]	8.00
实测	16	4096	200.139	[199.114, 201.195]	32.00
实测	32	1024	96.783	[96.007, 97.630]	16.00
模型预测	32	4096	363.973	[321.218, 387.926]	64.00
模型预测	64	1024	172.687	[130.706, 196.604]	32.00
模型预测	64	4096	688.414	[503.975, 759.970]	128.00

实测配置均包含 5 次预热和 20 次正式运行; 模型预测区间由实测配置拟合得到。通信量按 512 bytes/密文计算。

总耗时模型 $T = a + bK + cNK$ 在 24 个实测配置上的 R^2 为 0.9961, 留一组 MAPE 为 9.02%。最大预测配置 (64 客户端、 $K = 4096$) 的总耗时为 688.41 s, 预测区间为 [503.98, 759.97] s。全部实测配置的逐坐标解密结果与明文聚合一致, 最大绝对误差为零。该结果验证了真实 Paillier 实现的聚合正确性, 并显示在线开销主要随候选维度 K 与客户端数量 N 的乘积增长。




图 6 Paillier 总耗时缩放及实测-拟合关系

Figure 6 Paillier total-time scaling and measured-versus-fitted relation

圆点表示实测配置，星号表示模型预测配置；右图展示 24 个实测配置的模型拟合关系。

8.5 综合结果分析

Plain BPE 的五类攻击平均方向适配 AUC 为 0.5881，显示固定 C4 网站语料上存在可测的站点级成员信号；协议匹配基线和主 SA-DP-BPE 的对应数值分别为 0.5283 和 0.5158。主 SA-DP-BPE 在留出 C4 上的压缩效率变化约为 0.89%，AG News Macro-F1 为 0.9069。协议匹配基线说明候选域与批量训练路径本身也会改变成员风险，因此差分隐私的增量贡献需结合该基线理解。真实 Paillier 实验的逐标解密误差为零，在线耗时主要随 NK 增长。密码学安全性由形式分析给出，实验数据刻画经验成员风险、分词效用和运行开销；成员风险对应本文设定的迁移攻击。

9 讨论

9.1 训练期机密性与发布期隐私

Paillier 与差分隐私分别作用于训练过程和发布结果，形成互补的保护机制。Paillier 通过随机化密文与同态聚合保护单站点频率向量及未扰动聚合，站点级差分隐私则通过截断、离散噪声和顺序组合约束最终 Tokenizer 的发布分布。协议匹配无 DP 基线保留公共候选与批量训练路径，有助于区分训练机制变化和随机化对成员风险的影响。实验采用分层验证策略：大规模成员风险与效用评估使用协议等价明文聚合，密码学正确性与开销由独立的真实 2048-bit Paillier 实现测量。

非共谋双服务器模型使噪声明文、单客户端密文与解密能力分离。若服务器共谋，内部计算机密性将受到影响；只要随机化发布机制仍按协议执行，外部 Tokenizer 的站点级差分隐私分布继续由相同机制约束。这一区分说明训练期机密性、发布期隐私与系统信任假设需要在协议分析中分别建模。

9.2 隐私-效用权衡

主 SA-DP-BPE 配置采用 $\epsilon = 8$ 、公共范数分布第 75 百分位截断、 $b = 32$ 和 $K = 1024$ ，是开发集上成员风险、压缩效率与下游性能综合选择的结果。 $\epsilon = 4$ 的 SA-DP-BPE 提供更随机化，Local-DP-BPE 则以 $\epsilon = 16$ 展示另一种噪声位置和预算配置。不同方法之间的结果共同反映隐私预算、候选域、截断阈值和批量合并对最终性能的综合影响。

本文采用基本顺序组合，使每轮预算分配与总预算之间的关系清晰透明。更紧的隐私会计是改善多轮训练预算利用效率的一条后续方向。

9.3 扩展方向

第一, Paillier 明文空间为有限环, 而理论双边几何机制定义在整数域上。本文通过 2048-bit 模数和有符号安全区间保持编码、聚合与解码一致; 有限模域中的严格机制可采用周期化离散噪声, 或将超出安全区间的尾部概率纳入 (ϵ, δ) 会计。

第二, 面向服务器共谋和主动参与方, 可将门限解密、多方噪声生成以及计数合法性证明纳入同一协议扩展。多语言语料、更大客户端规模、不同预分词和下游任务可合并为统一的外部有效性评估。

代码与复现材料: <https://github.com/t12138ang/TokenizerPrivacyReport>

10 结论

本文针对公开 BPE 分词器可能泄露网站级训练成员信息的问题, 提出了融合站点级差分隐私与 Paillier 同态安全聚合的 SA-DP-BPE 方法。该方法以完整网站为隐私单位, 通过公共候选、确定性 L1 截断、双边几何噪声和批量兼容合并控制单站点对分词器训练的影响; 双服务器协议则在非共谋假设下实现密文统计聚合。形式分析表明, Paillier 在 DCRA 下为单站点上传提供计算机密性, 站点级随机机制及基本顺序组合为最终分词器发布提供隐私保证。

实验结果显示, 标准 Plain BPE、协议匹配无 DP 基线和主 SA-DP-BPE 的五类攻击平均方向适配 AUC 分别为 0.5881、0.5283 和 0.5158。主 SA-DP-BPE 的 AG News Macro-F1 为 0.9069, 与 Plain BPE 的 0.9068 保持相近水平; 留出 C4 语料上的压缩效率变化约为 0.89%。真实 2048-bit Paillier 实验验证了密文聚合的正确性, 并表明总开销主要随客户端数量与候选维度的乘积增长。在本文实验规模下, SA-DP-BPE 将发布侧成员风险、下游性能和 Paillier 在线开销纳入统一评估, 为网站级隐私保护的分词器训练提供了可复现的基线方案。

后续研究可聚焦有限模域中的严格离散机制, 以及面向服务器共谋与主动参与方的协议扩展; 多语言 and 不同下游任务可用于检验外部有效性。

参考文献

- [1] Jonathan Hayase, Alisa Liu, Yejin Choi, Sewoong Oh, and Noah A. Smith. Data mixture inference attack: BPE tokenizers reveal training data compositions. In *Advances in Neural Information Processing Systems*, volume 37, 2024. doi: 10.52202/079017-0285.
- [2] Meng Tong, Yuntao Du, Kejiang Chen, Weiming Zhang, and Ninghui Li. Membership inference attacks on tokenizers of large language models. In *35th USENIX Security Symposium*, 2026. URL <https://www.usenix.org/conference/usenixsecurity26/presentation/tong>. Accepted paper; full text: arXiv:2510.05699.
- [3] Reza Shokri, Marco Stronati, Congzheng Song, and Vitaly Shmatikov. Membership inference attacks against machine learning models. In *IEEE Symposium on Security and Privacy*, pages 3–18, 2017. doi: 10.1109/SP.2017.41.
- [4] Ahmed Salem, Yang Zhang, Mathias Humbert, Pascal Berrang, Mario Fritz, and Michael Backes. ML-Leaks: Model and data independent membership inference attacks and defenses on machine learning models. In *Network and Distributed System Security Symposium*, 2019. doi: 10.14722/ndss.2019.23119.
- [5] Nicholas Carlini, Steve Chien, Milad Nasr, Shuang Song, Andreas Terzis, and Florian Tramèr. Membership inference attacks from first principles. In *IEEE Symposium on Security and Privacy*, pages 1897–1914, 2022. doi: 10.1109/SP46214.2022.9833649.
- [6] Lauren Watson, Chuan Guo, Graham Cormode, and Alexandre Sablayrolles. On the importance of difficulty calibration in membership inference attacks. In *International Conference on Learning Representations*, 2022. URL <https://openreview.net/forum?id=3eIrli0TwQ>.
- [7] Pratyush Maini, Hengrui Jia, Nicolas Papernot, and Adam Dziedzic. LLM dataset inference: Did you train on my dataset? In *Advances in Neural Information Processing Systems*, volume 37, 2024. doi: 10.52202/079017-3941.
- [8] Wenjie Fu, Huandong Wang, Chen Gao, Guanghua Liu, Yong Li, and Tao Jiang. Membership inference attacks against fine-tuned large language models via self-prompt calibration. In *Advances in Neural Information Processing Systems*, volume 37, 2024. doi: 10.52202/079017-4290.
- [9] Mishaal Kazmi, Hadrien Lautreite, Alireza Akbari, Qiaoyue Tang, Mauricio Soroco, Tao Wang, Sébastien Gambs, and Mathias Lécuyer. PANORAMIA: Privacy auditing of machine learning models without retraining. In *Advances in Neural Information Processing Systems*, volume 37, 2024. doi: 10.52202/079017-1825.

- [10] Yuefeng Peng, Jaechul Roh, Subhransu Maji, and Amir Houmansadr. OSLO: One-shot label-only membership inference attacks. In *Advances in Neural Information Processing Systems*, volume 37, 2024. doi: 10.52202/079017-1991.
- [11] Yuntao Du, Jiacheng Li, Yuetian Chen, Kaiyuan Zhang, Zhizhen Yuan, Hanshen Xiao, Bruno Ribeiro, and Ninghui Li. Cascading and proxy membership inference attacks. In *Network and Distributed System Security Symposium*, 2026. doi: 10.14722/ndss.2026.230661.
- [12] Yuke Hu, Zheng Li, Zhihao Liu, Yang Zhang, Zhan Qin, Kui Ren, and Chun Chen. Membership inference attacks against vision-language models. In *34th USENIX Security Symposium*, pages 1589–1608, 2025. URL <https://www.usenix.org/conference/usenixsecurity25/presentation/hu-yuke>.
- [13] Shengfang Zhai, Huanran Chen, Yinpeng Dong, Jiajun Li, Qingni Shen, Yansong Gao, Hang Su, and Yang Liu. Membership inference on text-to-image diffusion models via conditional likelihood discrepancy. In *Advances in Neural Information Processing Systems*, volume 37, 2024. doi: 10.52202/079017-2358.
- [14] Yan Pang and Tianhao Wang. Black-box membership inference attacks against fine-tuned diffusion models. In *Network and Distributed System Security Symposium*, 2025. URL <https://www.ndss-symposium.org/ndss-paper/black-box-membership-inference-attacks-against-fine-tuned-diffusion-models/>.
- [15] Nicholas Carlini, Florian Tramèr, Eric Wallace, Matthew Jagielski, Ariel Herbert-Voss, Katherine Lee, Adam Roberts, Tom Brown, Dawn Song, Úlfar Erlingsson, Alina Oprea, and Colin Raffel. Extracting training data from large language models. In *30th USENIX Security Symposium*, pages 2633–2650, 2021. URL <https://www.usenix.org/conference/usenixsecurity21/presentation/carlini-extracting>.
- [16] Yuxin Wen, Leo Marchyok, Sanghyun Hong, Jonas Geiping, Tom Goldstein, and Nicholas Carlini. Privacy backdoors: Enhancing membership inference through poisoning pre-trained models. In *Advances in Neural Information Processing Systems*, volume 37, 2024. doi: 10.52202/079017-2652. URL https://proceedings.neurips.cc/paper_files/paper/2024/hash/97d008f7873b8dd55cb6dd343fc4386f-Abstract-Conference.html.
- [17] Zitao Chen and Karthik Pattabiraman. A method to facilitate membership inference attacks in deep learning models. In *Network and Distributed System Security Symposium*, 2025. URL <https://www.ndss-symposium.org/ndss-paper/diffence-fencing-membership-privacy-with-diffusion-models/>.
- [18] Matthew Jagielski, Jonathan Ullman, and Alina Oprea. Auditing differentially private machine learning: How private is private SGD? In *Advances in Neural Information Processing Systems*, volume 33, 2020.
- [19] Milad Nasr, Jamie Hayes, Thomas Steinke, Borja Balle, Florian Tramèr, Matthew Jagielski, Nicholas Carlini, and Andreas Terzis. Tight auditing of differentially private machine learning. In *32nd USENIX Security Symposium*, pages 1631–1648, 2023. URL <https://www.usenix.org/conference/usenixsecurity23/presentation/nasr>.
- [20] Thomas Steinke, Milad Nasr, and Matthew Jagielski. Privacy auditing with one (1) training run. In *Advances in Neural Information Processing Systems*, volume 36, 2023.
- [21] Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. In *Annual Meeting of the Association for Computational Linguistics*, pages 1715–1725, 2016. doi: 10.18653/v1/P16-1162.
- [22] Taku Kudo and John Richardson. SentencePiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. In *EMNLP System Demonstrations*, pages 66–71, 2018. doi: 10.18653/v1/D18-2012.
- [23] Cynthia Dwork, Frank McSherry, Kobbi Nissim, and Adam Smith. Calibrating noise to sensitivity in private data analysis. In *Theory of Cryptography Conference*, volume 3876 of *LNCS*, pages 265–284, 2006. doi: 10.1007/11681878_14.
- [24] Cynthia Dwork and Aaron Roth. The algorithmic foundations of differential privacy. *Foundations and Trends in Theoretical Computer Science*, 9(3–4):211–407, 2014. doi: 10.1561/04000000042.
- [25] Martin Abadi, Andy Chu, Ian Goodfellow, H. Brendan McMahan, Ilya Mironov, Kunal Talwar, and Li Zhang. Deep learning with differential privacy. In *ACM SIGSAC Conference on Computer and Communications Security*, pages 308–318, 2016. doi: 10.1145/2976749.2978318.
- [26] Ilya Mironov. Rényi differential privacy. In *IEEE Computer Security Foundations Symposium*, pages 263–275, 2017. doi: 10.1109/CSF.2017.11.
- [27] Peter Kairouz, Sewoong Oh, and Pramod Viswanath. The composition theorem for differential privacy. In *International Conference on Machine Learning*, volume 37 of *PMLR*, pages 1376–1385, 2015.
- [28] Clément L. Canonne, Gautam Kamath, and Thomas Steinke. The discrete gaussian for differential privacy. In *Advances in Neural Information Processing Systems*, volume 33, 2020.
- [29] Arpita Ghosh, Tim Roughgarden, and Mukund Sundararajan. Universally utility-maximizing privacy mechanisms. In *ACM Symposium on Theory of Computing*, pages 351–360, 2009. doi: 10.1145/1536414.1536464.

- [30] Pascal Paillier. Public-key cryptosystems based on composite degree residuosity classes. In *Advances in Cryptology – EUROCRYPT ’99*, volume 1592 of *LNCS*, pages 223–238, 1999. doi: 10.1007/3-540-48910-X_16.
- [31] Keith Bonawitz, Vladimir Ivanov, Ben Kreuter, Antonio Marcedone, H. Brendan McMahan, Sarvar Patel, Daniel Ramage, Aaron Segal, and Karn Seth. Practical secure aggregation for privacy-preserving machine learning. In *ACM SIGSAC Conference on Computer and Communications Security*, pages 1175–1191, 2017. doi: 10.1145/3133956.3133982.
- [32] James Bell, Keith Bonawitz, Adriana Gascón, Tancrède Lepoint, and Mariana Raykova. Secure single-server aggregation with (poly)logarithmic overhead. In *ACM SIGSAC Conference on Computer and Communications Security*, pages 1253–1269, 2020. doi: 10.1145/3372297.3417885.
- [33] Xinqian Wang, Xiaoning Liu, Shangqi Lai, Xun Yi, and Xingliang Yuan. SIGuard: Guarding secure inference with post data privacy. In *Network and Distributed System Security Symposium*, 2025. URL <https://www.ndss-symposium.org/ndss-paper/siguard-guarding-secure-inference-with-post-data-privacy/>.
- [34] Kaiyuan Zhang, Siyuan Cheng, Hanxi Guo, Yuetian Chen, Zian Su, Shengwei An, Yuntao Du, Charles Fleming, Ashish Kundu, Xiangyu Zhang, and Ninghui Li. SOFT: Selective data obfuscation for protecting LLM fine-tuning against membership inference attacks. In *34th USENIX Security Symposium*, pages 8135–8154, 2025. URL <https://www.usenix.org/conference/usenixsecurity25/presentation/zhang-kaiyuan>.
- [35] Yuefeng Peng, Ali Naseh, and Amir Houmansadr. Diffence: Fencing membership privacy with diffusion models. In *Network and Distributed System Security Symposium*, 2025. URL <https://www.ndss-symposium.org/ndss-program/symposium-2025/>.
- [36] Xinwei Zhang, Zhiqi Bu, Mingyi Hong, and Meisam Razaviyayn. DOPPLER: Differentially private optimizers with low-pass filter for privacy noise reduction. In *Advances in Neural Information Processing Systems*, volume 37, 2024. doi: 10.52202/079017-1323.
- [37] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020.
- [38] Xiang Zhang, Junbo Zhao, and Yann LeCun. Character-level convolutional networks for text classification. In *Advances in Neural Information Processing Systems*, volume 28, 2015.
- [39] Yuntao Du, Yuetian Chen, Hanshen Xiao, Bruno Ribeiro, and Ninghui Li. Imitative membership inference attack. In *35th USENIX Security Symposium*, 2026. URL <https://www.usenix.org/conference/usenixsecurity26/presentation/du>.